

TEL26: confronto fra dinamica all-atom e CG-ML

G-quadruplex ibrido 3+1 (2JPZ, (TTAGGG)₄TT), 10 copie × 26 nt. Struttura (P(r), g(r), R_g e coordinate collettive) e dinamica (MSD traslazionale e rotazionale, anche per ora di GPU), con la descrizione del modello. Progetto PaiNN-LT · MLCG_Framework_v2 · 7 ottobre 2026

Sintesi

- **Nucleo e struttura locale riprodotti entro il rumore del riferimento.** Le P(r) intramolecolari per canale si sovrappongono a quelle AA per 0,958-0,995, contro un tetto (metà contro metà della traiettoria AA) di 0,961-0,995; rmsd del nucleo: sovrapposizione 0,93 (tetto 0,94).
- **R_g medio corretto:** 0,800 nm contro 0,798 nm (AA); sovrapposizione 0,86 (tetto 0,89). Le copie AA restano per decine di ns su R_g diversi; nel CG tutte le copie oscillano attorno allo stesso valore.
- **Limite: i loop.** rmsd dei loop: sovrapposizione 0,58 (tetto 0,88), media 0,272 contro 0,217 nm. Il CG ha un solo bacino, mentre nell'AA ci sono stati metastabili che durano ns.
- **Efficienza per ora di GPU** (A100; 2 replicas per GPU, 54,2 ns/day aggregati, contro 137 ns/day dell'AA): traslazione 137× (MSD); rotazione 44× (decorrelazione); rmsd del nucleo 28×, che è il minimo fra gli osservabili confrontabili.

1. Sistemi, modelli e dati

	All-atom (riferimento)	CG-ML
Rappresentazione	169 000 atomi, solvente esplicito	10 × 86 = 860 beads (G: backbone S + basi B1-B5; T, A: un sito), solvente implicito
Hamiltoniana	campo di forze atomistico	prior fisici <i>lp2</i> (legami, angoli, diedri, 54 contatti Morse per copia, WCA) + residuo PaiNN (<i>re1_it30</i> , allenato a entropia relativa); sezione 2
Dinamica	dt 2 fs	Langevin, dt 4 fs, γ = 2; ESPResSo + plugin PaiNN
Traiettorie	1 × 135,8 ns, 10 copie	2 replicas × 20 ns (4 segmenti × 5 ns), 10 copie per replica
Frame analizzati	6788 frame ogni 20 ps (P(r): uno ogni 2)	struttura: ogni 20 ps (2008 frame); MSD e tempi: ogni 1 ps
Throughput	137 ns/day (1 A100 + 32 core)	54,2 ns/day aggregati (2 replicas su 1 A100 + 8 core)

Le coordinate collettive (R_g, rmsd del nucleo e dei loop, Q) sono calcolate per ogni copia dopo aver ricostruito la molecola attraverso il bordo periodico, rispetto alla struttura media della prima metà della traiettoria AA. Le sovrapposizioni fra distribuzioni sono $\int \min(p_{AA}, p_{CG}) dx$ (1 = identiche). Il **tetto** è la sovrapposizione fra seconda e prima metà della traiettoria AA: è il massimo accordo che si può chiedere con questa statistica di riferimento.

2. Il modello CG-ML: mappatura, prior e residuo PaiNN

L'energia potenziale del modello è la somma di due parti: $U(R) = U_{\text{prior}}(R) + U_{\text{ML}}(R)$. U_{prior} contiene termini analitici con un significato fisico (connettività, geometria locale, legami di Hoogsteen, impilamento, volume escluso), tarati sulla struttura all-atom mappata a 300 K. U_{ML} è un residuo appreso con una rete PaiNN e corregge ciò che i prior non descrivono. Solvente e ioni sono impliciti: nel modello di produzione non c'è un termine elettrostatico.

a mappatura e prior, vista laterale

b tettrade 1, vista lungo l'asse

c grafo PaiNN, $r_c = 1,26$ nm




Figura 1. Il modello CG sulla struttura nativa 2JPZ (struttura di partenza delle simulazioni AA, mappata sui siti CG; in grigio trasparente il DNA atomistico). **a**: siti colorati per tipo; legami armonici del backbone e scheletro rigido delle guanine in grigio scuro; contatti Morse tratteggiati per classe. **b**: la tettrade 1 (G4, G12, G16, G22) vista lungo l'asse del quadruplex, con i sei Morse B3-B3 (lati e diagonali) e i quattro Morse di Hoogsteen B2-B4. **c**: il grafo su cui agisce PaiNN per il sito B3 di G16; la sfera ha raggio $r_c = 1,26$ nm e contiene 76 degli altri 85 siti della copia. Non sono disegnati angoli, diedri e WCA. Figura generata con PyMOL.

2.1 Mappatura

Ogni copia di 26 nucleotidi è rappresentata da 86 siti di 8 tipi. Ogni sito è il centro di massa di un gruppo di atomi:

- **guanina**: sei siti uniti in un **corpo rigido**. S raccoglie zucchero e fosfato (P, O5', C5', C4', O4', C1', C3', C2', O3'). B1-B5 dividono la base: B1 = N9, C4; B2 = N3, C2, N2; B3 = N1, C6, O6; B4 = C5, N7; B5 = C8. B3 porta l'O6 rivolto al canale, B2 e B4 i donatori e accettori del secondo legame di Hoogsteen (N2-H...N7), B5 la faccia di impilamento;
- **timina e adenina**: un solo sito, il centro di massa dell'intero nucleotide;
- **dinamica**: Langevin in ESPResSo. Le 12 guanine sono corpi rigidi con massa e tensore d'inerzia dal mapping (6 gradi di libertà); A e T sono punti materiali. In tutto ci sono 114 gradi di libertà per copia.

Nota: la definizione di S elenca anche gli ossigeni non pontanti con i nomi O1P/O2P, mentre il campo di forze li chiama OP1/OP2. Non entrano quindi nel centro di massa, allo stesso modo nel riferimento e in tutti i dataset.

2.2 Prior fisici (insieme *lp2*)

I parametri vengono dalla struttura AA mappata a 300 K (10 copie, 136 ns). Legami e angoli sono ottenuti per inversione di Boltzmann. Per i Morse r_0 è la mediana della distanza, e $a = \sqrt{(kT / 2D\sigma^2)}$ usa la larghezza osservata σ , poi affinata iterativamente sulle distribuzioni del riferimento. I contatti sono specifici per coppia: legano due siti precisi della piega nativa. A runtime sono interazioni non legate su siti marcatori, con una coda smorzata fino a zero a r_{cut} , quindi si possono rompere senza errori di "bond broken".

termine	forma	siti	per copia	parametri
legami del backbone	$\frac{1}{2} k (r - r_0)^2$	sito S, A o T di residui consecutivi	25	k 136-3755 kJ mol ⁻¹ nm ⁻² ; r_0 0,58-0,70 nm
angoli del backbone	$\frac{1}{2} k (\theta - \theta_0)^2$	tre residui consecutivi	24	k 5-324 kJ mol ⁻¹ rad ⁻² ; θ_0 117-157°
diedri del backbone	coseno ($n = 1$), smorzato quando un angolo tende a 180°	quattro residui consecutivi	23	K 2,4-74 kJ/mol
torsione di impilamento	coseno ($n = 1$)	B3-B5-B5-B3 di guanine sovrapposte	8	K 391-774 kJ/mol (157-310 kT)
Morse nella tetrade	$D [1 - e^{-a(r-r_0)^2}]^2$	B3-B3, lati e diagonali (K_4)	18	r_0 0,38-0,65 nm; a 3,5-11,5 nm ⁻¹
Morse di Hoogsteen	idem	B2-B4 (N2-H...N7)	12	r_0 0,31-0,57 nm; a 6,1-11,0 nm ⁻¹
Morse di impilamento	idem	B5-B5, stesso tratto, tetradi adiacenti	8	r_0 0,37-0,45 nm; a 5,9-8,9 nm ⁻¹
cappucci dei loop	idem	basi di loop/code contro la faccia delle tetradi esterne	16	r_0 0,45-0,89 nm; a 2,3-5,1 nm ⁻¹
volume escluso	WCA, LJ 12-6 troncato e traslato a $2^{1/6}\sigma$	tutte le coppie di tipi (esclusi 1-2 e 1-3)	36 coppie di tipi	ϵ 3,15 kJ/mol; σ 0,24-0,68 nm

Tutti i Morse hanno $D = 50$ kJ/mol (circa 20 kT a 300 K). In totale sono 2700 kJ/mol per copia: è un modello del solo stato nativo, di tipo Gō, adatto a 300 K ma non all'unfolding (vedi sezione 9).

2.3 Residuo PaiNN

U_{ML} è la somma di energie di sito, $U_{\text{ML}} = \sum_i \epsilon_i$, calcolate da una rete PaiNN (polarizable atom interaction neural network, Schütt et al. 2021). La rete è equivariante per rotazioni e invariante per traslazioni e per permutazioni di siti dello stesso tipo:

- **ingresso:** tipo del sito (8 specie → embedding di dimensione $D = 64$) e posizioni. Il grafo comprende tutte le coppie di siti entro $r_c = 1,2616$ nm, anche fra copie diverse (figura 1c);
- **base radiale:** 32 gaussiane con centri fra 0 e r_c e larghezza $r_c/32$, moltiplicate per la funzione di taglio di Toxvaerd $x^4/(x^4 + \alpha^4)$, con $x = (r_c - r)/r_c$ e $\alpha = 0,1$. L'energia è liscia a r_c fino alla derivata terza;
- **interazione:** 2 blocchi messaggio + aggiornamento sulle feature scalari $s_i \in \mathbb{R}^{64}$ e vettoriali $v_i \in \mathbb{R}^{3 \times 64}$ (forma canonica di PaiNN, attivazioni SiLU);
- **uscita:** MLP $64 \rightarrow 32 \rightarrow 1$ sullo scalare finale di ogni sito. A ogni ϵ_i si sottrae il valore della stessa specie isolata, così $U_{\text{ML}} \rightarrow 0$ per siti lontani da tutto. In tutto la rete ha 106 049 parametri;
- **forze:** $F = -\nabla U_{\text{ML}}$ per differenziazione automatica sulle posizioni dei siti. Sulle guanine si riducono a forza e momento del corpo rigido. La rete gira nel plugin ESPResSo in libtorch, FP32 su GPU, e le forze sono conservative per costruzione.

Allenamento: entropia relativa, non force matching. Le forze AA istantanee proiettate sui siti CG sono dominate dal rumore: la parte che si può apprendere vale $R^2 \approx 0,5-1$ %. Il force matching sopra prior già tarati peggiorava la struttura (sovrapposizione intra da 0,976 a 0,94). Il residuo è

stato quindi allenato minimizzando l'entropia relativa $S_{\text{rel}} = \langle \ln p_{\text{AA}}/p_{\text{CG}} \rangle_{\text{AA}}$, che usa solo le posizioni. Il gradiente è $\beta[\langle \partial U/\partial \theta \rangle_{\text{AA}} - \langle \partial U/\partial \theta \rangle_{\text{CG}}]$; i prior non vi compaiono perché non dipendono da θ .

- ogni iterazione fa 25 ps di MD CG con il modello corrente; i campioni vengono riusati per ripesatura finché la taglia efficiente per copia resta ≥ 50 %;
- il passo è controllato da una regione di fiducia, e il 20 % finale della traiettoria AA è tenuto fuori come controllo;
- **re0**: 30 iterazioni sopra i prior lp1, partendo da $U_{\text{ML}} \equiv 0$ (ultimo strato dell'uscita a zero). **re1**: 30 iterazioni sopra lp2 (lp1 più i cappucci dei loop), partendo da re0_it30. Il modello di produzione è re1_it30;
- dati AA: posizioni mappate di prod-1 (136 ns, 10 copie, un frame ogni 20 ps) a 300 K.

Effetto del residuo sulla sovrapposizione intra (tutti i siti), a parità di protocollo: prior lp2 0,981 $\rightarrow$ lp2 + re1_it30 0,994, con un tetto AA contro AA di 0,9955. Il guadagno è maggiore sul canale B3-B3 (0,84 $\rightarrow$ 0,97).

3. Distribuzioni di coppia intramolecolari P(r)

Per ogni canale, $P(r)$ è l'istogramma normalizzato delle distanze fra siti della stessa copia (stessi bin e stessa normalizzazione dello script 44). I canali separano i contributi principali della struttura: B3-B3 per gli appaiamenti di Hoogsteen nelle tetradi, B5-B5 per l'impilamento delle tetradi, S-S per il backbone; il canale "tutti i siti" li somma, loop compresi.




Figura 2. $P(r)$ intramolecolari per canale. Blu: AA su 136 ns; arancione: CG-ML su 2×20 ns; grigio tratteggiato e punteggiato: prima e seconda metà dell'AA. In alto a destra la sovrapposizione CG-AA e il tetto (metà 2 contro metà 1).

canale	CG-ML contro AA	tetto (metà 2 - metà 1 AA)	differenza
tutti i siti	0,995	0,995	-0,001
B3-B3 (legami H)	0,976	0,979	-0,003
B5-B5 (stacking)	0,967	0,971	-0,004
S-S (backbone)	0,958	0,961	-0,003

In tutti i canali il CG-ML raggiunge il tetto: lo scarto è al più 0,004, cioè dentro la variazione fra le due metà del riferimento. Posizioni e altezze dei picchi coincidono: per B3-B3 0,34, 0,445, 0,65 e 0,84 nm; per S-S il primo vicino a 0,595 nm. Le differenze residue, per esempio i picchi S-S a 1,17 e 1,42 nm leggermente più alti nel CG, hanno la stessa ampiezza delle fluttuazioni fra le metà AA. La geometria del nucleo (tetradi, impilamento, backbone) è quindi riprodotta a livello di distribuzione, non solo in media.

4. $g(r)$ fra copie diverse (corto raggio)

La $g(r)$ intermolecolare conta le coppie di siti su copie diverse. Fino a 2,0 nm, la distanza massima calcolata, descrive solo gli incontri ravvicinati fra copie: con $R_g \approx 0,8$ nm le copie si toccano di rado e $g(r)$ resta molto sotto 1, nella zona di volume escluso.




Figura 3. $g(r)$ fra siti di copie diverse, stessi colori della figura 2. Le due metà AA differiscono di un fattore ~ 5 : gli incontri fra copie nell'AA sono pochi eventi lunghi.

canale	CG-ML contro AA	metà 2 - metà 1 AA
tutti i siti	0,909	0,852
B3-B3 (legami H)	0,679	0,000
B5-B5 (stacking)	0,925	0,826
S-S (backbone)	0,914	0,769

Nell'AA la prima metà quasi non ha contatti fra copie, la seconda molti di più: questi contatti sono eventi rari e non ergodici su 136 ns, e il riferimento non li campiona. La sovrapposizione CG-AA (0,68-0,93) supera quella fra le due metà AA (0-0,85), quindi qui la metrica non discrimina. Il CG-ML ha contatti fra copie un po' più frequenti della media AA, simili alla seconda metà. **Conclusione:** con questo riferimento la struttura fra copie a corto raggio non è verificabile. Per la $g(r)$ completa fra copie (distanze fino a metà box) basta rilanciare lo script 53 con `--rmax` più grande, ma l'incertezza AA resterà quella dettata da 10 copie in una sola box.

5. Raggio di girazione




Figura 4. Sinistra: distribuzione di R_g (AA: singole copie in linea sottile, insieme in linea spessa; CG-ML: tutte le copie e replicas). Destra: serie temporali con media mobile di 1 ns, AA su 136 ns e CG-ML (replica r0) su 20 ns, stessa scala verticale.

	AA	CG-ML
media $\pm$ deviazione standard (nm)	0,798 $\pm$ 0,008	0,800 $\pm$ 0,010
medie delle singole copie (nm)	0,784–0,806	tutte $\approx$ 0,800
τ a 1/e (script 47)	5,6 ns	2,4 ps
sovrapposizione con l'AA (tetto)	–	0,86 (0,89)

Il valore medio è corretto entro 0,002 nm. La distribuzione CG è un po' più larga di quella AA complessiva e molto più larga di quella di una singola copia AA. Il motivo è nelle serie temporali: nell'AA ogni copia resta per decine di ns su un proprio R_g (la copia più compatta a 0,78 nm per gran parte della traiettoria), con un rilassamento lento di 5–10 ns legato ai riarrangiamenti dei loop. Nel CG la media su 1 ns è piatta e uguale per tutte le copie, perché R_g si decorrela in pochi ps. Il CG campiona quindi un unico bacino "medio" al posto degli stati che l'AA visita lentamente. Per R_g il rapporto fra i τ (~ 2400) misura processi diversi e non è un'accelerazione.

6. Altre coordinate collettive




Figura 5. Distribuzioni di rmsd del nucleo, rmsd dei loop e frazione di contatti nativi Q (grigio: metà AA). Nei titoli la sovrapposizione CG-AA e il tetto.

coordinata	AA media $\pm$ std	CG-ML media $\pm$ std	sovrapposizione	tetto
R_g (nm)	0,798 $\pm$ 0,008	0,800 $\pm$ 0,010	0,86	0,89
rmsd nucleo (nm)	0,044 $\pm$ 0,008	0,044 $\pm$ 0,009	0,93	0,94
rmsd loop (nm)	0,217 $\pm$ 0,053	0,272 $\pm$ 0,060	0,58	0,88
Q	0,908 $\pm$ 0,013	0,909 $\pm$ 0,009	0,85	0,88

Il nucleo è al tetto: rmsd 0,044 nm in entrambi, sovrapposizione 0,93 contro 0,94. Q ha la stessa media ma una distribuzione un po' più stretta nel CG (std 0,009 contro 0,013). I loop sono l'unico scarto netto: nel CG sono più mobili e lontani dalla struttura media (0,27 contro 0,22 nm), e manca la popolazione a rmsd basso (0,13–0,2 nm) che nell'AA corrisponde agli stati compatti dei loop. Le diagnosi degli script 49–52 attribuiscono lo scarto a stati metastabili assenti nel CG (stato 1 del loop 3, stato minore del loop 2) e a un registro di appaiamenti in parte sbagliato (T2–A15 in eccesso).




Figura 6. Energia libera $F = -kT \ln p(rmsd\ nucleo, Q)$, AA e CG-ML. La JSD fra le FES (script 46) è 0,0787, uguale al tetto AA contro sé stesso (0,0786); il CG è più rumoroso per il numero minore di frame (20 080 contro 67 880 copie-frame).

7. Dinamica: MSD traslazionale e rotazionale

MSD del centro di massa di ogni copia e MSD angolare dell'orientazione del nucleo (allineamento di Kabsch, rotazioni fra frame successivi sommate come vettori di rotazione nel sistema del laboratorio; script 48). Le curve si fermano a un quarto della durata di ogni traiettoria. Nella riga in basso l'asse dei tempi è convertito in ore di GPU con il throughput misurato.




Figura 7. In alto: MSD in funzione del tempo simulato; tratteggiato $6Dt$ con D dal tratto lineare. In basso: le stesse curve in funzione delle ore di GPU A100 (AA 137 ns/day; CG-ML 54,2 ns/day aggregati su 2 replicas).

	AA	CG-ML	rapporto CG/AA
D (nm ² /ns), retta	0,093	32,4	347
τ_v dal fit di Langevin (ps)	1,2	105	
MSD traslazionale per ora di GPU (nm ²)	3,19	439	137×
D_{rot} (rad ² /ns), retta	0,049	39,1	793
τ_{p2} (ps)	3313	29,8	$\alpha = 111$
$1/(6D_{rot})$ (ps)	3378	4,3	
MSD angolare per ora di GPU (rad ²)	1,69	530	314× (sovrastima)
decorrelazione dell'orientazione per ora di GPU			44×

- **Traslazione:** nel CG il regime è balistico fino a $\sim 0,1-0,3$ ns ($\tau_v \approx 100$ ps), poi diffusivo; D è 0,68 del valore atteso $kT/(N\gamma)$ per una molecola isolata. Nel regime diffusivo l'MSD per ora di GPU vale $6D \times$ (ns per ora), cioè $\alpha \times$ rapporto di throughput: 137×. A pochi minuti di calcolo il CG è ancora balistico e il guadagno è minore.

- **Rotazione:** nell'AA $\tau_{p2} \approx 1/(6D_{rot})$, quindi la rotazione è diffusiva e il metodo è confermato. Nel CG τ_{p2} è ~ 7 volte $1/(6D_{rot})$: l'orientazione si decorrela già nel regime inerziale (γ basso), e l'MSD angolare sovrastima il guadagno sul campionamento delle orientazioni. Per la rotazione il numero da usare è quello della decorrelazione, $44\times$.

8. Efficienza per GPU

Efficienza = $\alpha \times (\text{ns/day}_{CG} / \text{ns/day}_{AA})$, con $\alpha = \tau_{AA}/\tau_{CG}$ (tempi a 1/e dello script 47) oppure il rapporto dei D; $\text{ns/day}_{CG}/\text{ns/day}_{AA} = 54,2/137 = 0,396$.

osservabile	τ AA	τ CG-ML	α	efficienza per GPU
traslazione (MSD)			347 (rapporto dei D)	$137\times$
siti del nucleo	175 ps	0,48 ps*	363*	$\sim 140\times$
rotazione (τ_{p2})	3,31 ns	29,8 ps	111	$44\times$
rmsd del nucleo	78,5 ps	1,10 ps	72	$28\times$ (minimo)
R_g , loop	5,6, 7,0 ns	2,4, 2,9 ps	~ 2400	non interpretabile

* Con un frame ogni ps il τ CG dei siti del nucleo ($\sim 0,5$ ps) non è risolto (lo script 47 dà 0,69 ps per interpolazione); si usano τ e α dalla corsa campionata ogni 0,5 ps.

Il numero da citare è il minimo fra gli osservabili confrontabili: **$\sim 28\times$ per GPU** (rmsd del nucleo), con traslazione e moti locali del nucleo a $\sim 140\times$ e rotazione a $\sim 44\times$. Per budget di nodo il vantaggio può crescere fino a $\sim 4\times$, perché l'AA occupa 32 core contro 8 del CG; serve il throughput AA con 8 core per GPU per fissarlo.

9. Limiti e avvertenze

- **Loop:** un solo bacino al posto degli stati metastabili AA. Mancano lo stato 1 del loop 3 (26 %) e lo stato minore del loop 2; la coda 5' è troppo mobile; il contatto T2-A15 è in eccesso (0,56 contro $0,24 \pm 0,09$). I contatti dipendenti dallo stato (lp2c0) sono stati provati e non adottati: con un solo sito per T e A la specificità del registro non si ottiene con contatti fra coppie.
- **Riferimento AA non ergodico sui loop:** il 17-61 % della varianza dei loop è fra copie e i tempi lenti sono 4-10 ns su 136 ns. Le popolazioni AA degli stati dei loop hanno errori grandi, e i tetti su loop e R_g sono ottimistici: le due metà condividono le stesse copie bloccate.
- **Solo stato nativo:** i 54 Morse a 50 kJ/mol per copia tengono il quadruplex chiuso a qualunque temperatura accessibile. Con i soli prior, su una copia, nessuna tetrad si apre fra 300 e 600 K in 250 ns, e l'energia potenziale cresce come quella di un sistema armonico. Il modello serve per la struttura e la dinamica attorno al nativo; per la termodinamica di unfolding le profondità dei contatti vanno ricalibrate (lavoro in corso, cartella *tel26_unfold*).
- **$g(r)$ fra copie:** verificata solo a corto raggio (≤ 2 nm), dove anche l'AA non converge.
- **Efficienza:** per GPU A100, a parità di hardware; il rapporto per GPU-ora dipende dal throughput del nodo, che varia di ~ 20 % fra nodi a parità di codice.

Appendice: provenienza dei dati

Dati: *report_data.npz* generato su Leonardo da *53_tel26_report_data.py* ($P(r)$ e $g(r)$ con le routine dello script 44; coordinate collettive con lo script 46; curve MSD da *msd_wall_prod.json*, script 48; tempi da *ts_prod.json*, script 47). Riferimento AA: *tel26_lp1_dataset.bin*. CG-ML: *prod_re1_s0{1..4}_r{0,1}.samples.npz* (catena *prod_re1*, modello lp2 + re1_it30). Figure e PDF: *make_figs.py*, *build_report.py* nella cartella *tutorials/tel26/report*. Parametri: $P(r)$ con un frame AA ogni 2, CG ogni 20 ps, 200 bin fino a 2 nm.